

Le transfert horizontal de gènes médié par les bactériophages remodèle le génome accessoire d'un isolat clinique multirésistant d'*Escherichia coli* ST354



Sarra Benmoumou-Hosni^{1*}, Atika Meklat², Ikram Haleche²

¹ Laboratoire de Biologie des Systèmes Microbiens (LBSM), École Normale Supérieure de Kouba, Alger, Algérie

² Laboratoire de Biotechnologies, Environnement et Santé, Université de Blida 1, Blida, Algérie

| * Auteure correspondante : sarra_ben@oulook.fr



1. INTRODUCTION & CONTEXTE DE RECHERCHE

CONTEXTE CLINIQUE & PANGÉNOMIQUE

- **Pathogène ExPEC ST354** : *Escherichia coli* pathogène extra-intestinal (ExPEC) ST354 constitue un clone clinique émergent multirésistant (MDR) responsable d'infections urinaires graves, bactériémies et sepsis.
- **Dynamique du Pangénome Ouvert [2]** : Les génomes pathogènes possèdent un pangénome ouvert (exposant $\alpha = 0,42 \pm 1,0$ [2]) accumulant en continu du matériel génétique étranger via transfert horizontal de gènes (HGT [7]).
- **« Matière Noire » Accessoire** : Près de 30 à 40 % des CDS prédites restent annotées comme 'protéines hypothétiques', dissimulant de nouveaux facteurs de résistance (AMR) et de virulence inexplorés.


MOTIVATION SCIENTIFIQUE

- **Zone d'Ombre d'Homologie** : Les algorithmes d'alignement classiques (BLASTp [1], HMM Pfam) échouent lorsque l'identité de séquence chute sous 20–25 %, laissant les homologues divergents non annotés [1] .
- **Éléments Mobiles & Dérive [7]** : De nouveaux gènes d'AMR et cytotoxines portés par des éléments transposables (IS) ou prophages échappent à la surveillance génomique en raison de la dérive de séquence [7] .
- **Pipelines Indépendants de la Séquence [3-5]** : Bien que la modélisation 3D (AF3 [3]) et les modèles de langage (ESM-2 [5]) permettent un matching structural (Foldseek [4]), des frameworks intégrés manquent.

OBJECTIFS & TRAVAIL PROPOSÉ

- **Pipeline Pangénome-vers-Structure** : Développement d'un framework computationnel indépendant de la séquence en 7 étapes combinant filtrage pangénomique [2], modélisation 3D [3] et deep learning [5].
- **Validation Biophysique Multicouche [6]** : Couplage entre comparaison structurale Foldseek, clustering ESM-2 (650M) dans l'espace latent [5], docking MM-GBSA et simulations de dynamique moléculaire (MD).
- **Candidats Prioritaires chez QA5221** : Priorisation et validation de 4 gènes candidats accessoires prioritaires (GNAT_KA27, Ehly_61, OAgP_161, OAT_371) chez la souche clinique ExPEC QA5221.


2. MATÉRIEL & MÉTHODES



- **1. Isolat Clinique & Assemblage** : ExPEC MDR QA5221 (ST354) séquencé sur Illumina MiSeq (2x250 bp) ; assemblage de novo SPAdes ; annotation Prokka (4 647 CDS).
- **2. Pangénomique Multi-Échelle** : Clustering Panaroo [2] sur 32 génomes locaux ST354, 401 de lignée et 801 globaux d'E. coli en mode strict clean (80–95 % d'identité) [2] .
- **3. Modélisation Structurale & PLM** : Modèles 3D ESMFold & AF3 [3] ; recherche d'homologie Foldseek [4] (PDB/Swiss-Prot) ; embeddings ESM-2 650M (1280-D) [5].
- **4. Dynamique Moléculaire (MD)** : Simulations MD OpenMM en solvant explicite (127,78 ns pour GNAT_KA27) et en bicouche lipidique POPC/POPE CHARMM-GUI [6] (90,24 ns pour Ehly_61) [6] .

3. RÉSULTATS & DÉCOUVERTES STRUCTURALES

Partitionnement du Pangénome & Biais en AT



• **Ouverture du Pangénome** : Pangénome total étendu à 9 184 clusters sur 801 génomes d'E. coli. L'exposant de Heaps $\alpha = 0,42 \pm 1,0$ confirme un pangénome ouvert en constante expansion.

• **Partitions Pangénomiques** : Soft Core : 3 298 (35,9 %) ; Shell : 2 295 (25,0 %) ; Cloud : 3 591 (39,1 %). Les singletons nuages constituent un réservoir massif d'AMR.

• **Dépression Compositionnelle en GC/GC3** : Les singletons présentent une baisse significative du taux de GC (cœur : 51,86 % vs singletons : 46,78 %, $p < 0,001$), signature directe d'une acquisition par HGT.

4 Familles Protéiques Candidates Prioritaires



• **GNAT_KA27 (KNGPFPPJ_02769)** : N-acétyltransférase GCN5 (TM = 0,81) ; docking dans le site actif révélant une forte affinité pour la kanamycine ($\Delta G = -22,91$ kcal/mol).

• **Ehly_61 (KNGPFPPJ_00061)** : Cytotoxine entérohémolysine (TM = 0,74) intégrée dans un prophage de 38,5 kb ; configuration stable en bicouche POPC/POPE.

• **OAgP_161 (KNGPFPPJ_03161)** : O-antigène polymérase Wzy divergente (TM = 0,68) insérée dans le cluster LPS, indiquant une commutation de sérotype.

• **OAT_371 (KNGPFPPJ_04371)** : Autotransporteur plasmidique (Sécrétion Type V) ; domaine tonneau- β C-terminal stable en MD (RMSD = $1,53 \pm 0,09$ Å).

ENTONNOIR DE SÉLECTION DES CANDIDATS




4 647
CDS Totales QA5221

142
Singletons Cloud (Filtre HGT)

-22,91
kcal/mol ΔG de Liaison

127,78
ns Stabilité Trajectoire MD


Espace Latent du Modèle de Langage ESM-2 (650M)



• **Alignement dans l'Espace Latent** : Les embeddings 1280-D projetés en UMAP démontrent un co-clustering fonctionnel avec des standards caractérisés d'AMR et de virulence.

• **Franchissement de la Chute de Séquence** : Les singletons prioritaires se projettent dans des classes fonctionnelles définies malgré une identité de séquence sous le seuil de 20 %.

Simulations MD en Solvant Explicite et Membrane



• **GNAT_KA27 en Solvant Explicite** : Maintien de l'intégrité du repliement sur 127,78 ns (RMSD squelette = $2,73 \pm 0,20$ Å). Le calcul MM-GBSA révèle un écart de sélectivité de 10,8 kcal/mol pour les aminoglycosides.

• **Insertion Membranaire d'Ehly_61** : Simulation de 90,24 ns en bicouche POPC/POPE confirmant une topologie hélicoïdale transmembranaire stable (RMSD = $5,62 \pm 1,04$ Å).

4. DISCUSSION

- **Topologie Structurale et Zone d'Ombre** : Les recherches de séquence classiques [1] échouent à annoter ~35 % du pangénome nuage. L'intégration du repliement 3D [3,4] et des embeddings ESM-2 [5] surmonte la dérive de séquence.
- **Éléments Génétiques Mobiles (MGE)** : Le biais compositionnel en AT, l'encadrement par des éléments d'insertion (IS) et l'intégration prophagique confirment l'acquisition par transfert horizontal de gènes (HGT [7]).
- **Feuille de Route Expérimentale** : Bien que la biophysique apporte une preuve de viabilité solide [6], la validation au laboratoire (essais enzymatiques in vitro, expression recombinante, hémolyse) demeure indispensable pour confirmer la cinétique [6].

5. CONCLUSION

- **Framework Pangénome-vers-Structure** : Établissement d'un pipeline complet et automatisé pour prioriser et annoter les singletons accessoires chez les bactéries pathogènes multirésistantes.
- **Annotations Fonctionnelles Résolues** : Identification et validation de 4 familles de candidats prioritaires (GNAT, entérohémolysine, polymérase Wzy, autotransporteur) chez la souche ExPEC QA5221.
- **Surveillance de l'AMR** : Approche transférable et généralisable pour décrypter la « matière noire » génomique des infections émergentes à l'échelle globale.

6. RÉFÉRENCES

- [1] Altschul SF et al. Basic local alignment search tool. J Mol Biol. 1990;215(3):403-410.
- [2] Tonkin-Hill G et al. Producing polished prokaryotic pan-genomes with Panaroo. Genome Biol. 2020;21(1):180.
- [3] Abramson J et al. Accurate structure prediction of molecular interactions with AlphaFold 3. Nature. 2024;630:493-500.
- [4] van Kempen M et al. Fast and accurate protein structure search with Foldseek. Nat Biotechnol. 2024;42:243-246.
- [5] Lin Z et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. Science. 2023;379:1123-1130.
- [6] Jo S, Kim T, Im W. CHARMM-GUI: a web-based graphical user interface for CHARMM. J Comput Chem. 2008;29:1859-1865.
- [7] Partridge SR et al. Mobile genetic elements associated with antimicrobial resistance. Clin Microbiol Rev. 2018;31:e00088-17.